套利定价理论与多因子模型

Mingyu Shu
shumingyu@foxmail.com

2026 年 5 月 5 日

本讲提纲

第一部分：APT 理论

1. 套利定价理论
   - 因子模型设定
   - APT 推导与证明
2. Fama-French 因子模型
   - 三因子与五因子模型
   - 实证表现

第二部分：因子动物园与进展

3. 因子动物园问题
   - Harvey 等批评
   - 多重检验调整
4. 机器学习因子模型
5. 最新进展（2022+）

APT：设定与假设

线性因子模型（Ross, 1976, *JFE*）

资产收益服从 K 因子结构：

$$R_i = E[R_i] + \sum_{k=1}^{K} b_{ik} F_k + \epsilon_i$$

其中 F_k 为因子实现，b_{ik} 为因子载荷，ϵ_i 为特质风险。

假设：

1. 因子零均值：$E[F_k] = 0$
2. 特质风险不相关：$E[\epsilon_i \epsilon_j] = 0 \ (i \neq j)$
3. 因子与残差不相关：$E[F_k \epsilon_i] = 0$
4. 无套利机会

APT：无套利论证

构造零成本、零因子风险组合：

$$\sum_{i=1}^{N} \omega_i = 0 \quad \text{（零成本）}$$

$$\sum_{i=1}^{N} \omega_i b_{ik} = 0, \quad k = 1, \ldots, K \quad \text{（零因子风险）}$$

组合收益：

$$R_p = \sum_{i=1}^{N} \omega_i E[R_i] + \sum_{k=1}^{K} \underbrace{\left(\sum_{i=1}^{N} \omega_i b_{ik} \right)}_{=0} F_k + \sum_{i=1}^{N} \omega_i \epsilon_i$$

当 $N \to \infty$**：** $\mathrm{Var}(\sum_i \omega_i \epsilon_i) \to 0$（分散化）
无套利 $\Rightarrow$ 对所有此类组合 $\sum_i \omega_i E[R_i] = 0$。

APT：主要结论

APT (Ross, 1976)

若无套利，期望收益满足：

$$E[R_i] = r_f + \sum_{k=1}^{K} b_{ik}\lambda_k$$

其中 λ_k 为因子 k 的风险溢价。

证明： 由无套利条件，$E[R_i]$ 必须在 $\mathbf{1}$ 和 $\{b_{ik}\}_{k=1}^{K}$ 的张成空间内。否则可构造套利组合。

核心洞见： APT **不需要**：

- 均值-方差优化
- 识别市场组合
- 超越无套利的效用假设

APT 与 CAPM 比较

特征	CAPM	APT
因子数	1（市场）	K（多个）
假设	均值-方差效用	无套利
市场组合	需要	不需要
可检验性	联合假设	因子识别

关系：当市场组合为唯一因子时，CAPM 是 APT 的特例。

Fama-French 三因子模型

FF3 (Fama & French, 1993, *JF*)

$$E[R_i] - r_f = \beta_i^M (R_M - r_f) + \beta_i^{SMB} E[\text{SMB}] + \beta_i^{HML} E[\text{HML}]$$

因子：

- **SMB**（小减大）：规模因子
- **HML**（高减低）：价值因子
- 市场超额收益：$R_M - r_f$

构造：按规模和账面市值比将股票分为 2×3 组合。

Fama-French 五因子模型

FF5 (Fama & French, 2015, *JFE*)

$$E[R_i] - r_f = \beta_i^M \text{MKT} + \beta_i^{SMB} \text{SMB} + \beta_i^{HML} \text{HML} + \beta_i^{RMW} \text{RMW} + \beta_i^{CMA} \text{CMA}$$

额外因子：

- **RMW**（强减弱）：盈利能力因子
- **CMA**（保守减激进）：投资因子

动机：股利折现模型意味着：

$$\frac{E[D_t]}{P_0} = r_f + \beta(\text{MKT}) + \text{规模} + \text{价值} + \text{盈利} + \text{投资}$$

Carhart 四因子模型

Carhart (1997, *JF*)

$$E[R_i] - r_f = \beta_i^M \text{MKT} + \beta_i^{SMB} \text{SMB} + \beta_i^{HML} \text{HML} + \beta_i^{WML} \text{WML}$$

动量因子：

- **WML**（赢者减输者）：动量因子
- 基于 Jegadeesh & Titman (1993, *JF*)
- 过去赢者在 3–12 个月内跑赢输者

对 EMH 的挑战：动量难以用基于风险的模型解释。

因子模型估计

时间序列回归：

$$R_{it} - r_{ft} = \alpha_i + \sum_{k=1}^{K} \beta_{ik} F_{kt} + \epsilon_{it}$$

GRS 检验 (Gibbons et al., 1989, *JFE*)：

$$\text{GRS} = \frac{T-N-K}{N} \cdot \frac{\hat{\alpha}^\top \hat{\Sigma}^{-1} \hat{\alpha}}{1 + \bar{F}^\top \hat{\Omega}^{-1} \bar{F}} \sim F_{N,T-N-K}$$

联合检验 $H_0 : \alpha_1 = \cdots = \alpha_N = 0$。

$\hat{\Sigma}$：残差协方差，$\hat{\Omega}$：因子协方差，$\bar{F}$：因子均值收益。

q 因子模型

Hou-Xue-Zhang q 因子模型 (2015, *RFS*)

$$E[R_i] - r_f = \beta_i^{MKT} + \beta_i^{ME} + \beta_i^{I/A} + \beta_i^{ROE}$$

因子：

- **ME**：市值（规模）
- **I/A**：投资/资产
- **ROE**：净资产收益率（盈利能力）

理论基础：投资 q 理论 (Cochrane, 1991, *JF*; Liu et al., 2009, *RFS*)。

随机折现因子表示

SDF 表示

任何资产定价模型可写为：

$$E[R_i] - r_f = -r_f \cdot \mathrm{Cov}(R_i, M)$$

其中 M 为随机折现因子 (SDF)。

线性因子模型的 SDF：

$$M = a_0 - \sum_{k=1}^{K} a_k F_k$$

联系：

- CAPM：$M = a_0 - a_1 R_M$
- FF3：$M = a_0 - a_1 R_M - a_2 \mathrm{SMB} - a_3 \mathrm{HML}$
- Hansen GMM：检验 $E[MR_i] = 1$ (Hansen, 1982, *Econometrica*)

机器学习因子模型

深度因子模型（2023–2025）：

- **自编码器资产定价** (Kelly et al., 2023, *RFS*)：

$$E[R_i] = \beta_i^\top \lambda, \quad \beta_i = g(\text{公司特征}; \theta)$$

  其中 g 为神经网络
- **工具化 PCA**：从特征获取时变载荷
- **生成式 AI**：LLM 从金融文本中提取因子

核心结果：基于 ML 的模型比 OLS 因子模型 R^2 提高 0.5%–1.5%。

因子动物园与模型选择

因子动物园问题： > 600 个已发表因子（Harvey et al., 2016; 更新至 2024）。

近期解决方案：

- **双重选择 LASSO**：Chernozhukov et al. (2024) 用于有效推断
- **Knockoff 滤波**：控制因子选择中的错误发现率
- **贝叶斯模型平均**：对因子模型取平均

$$\hat{R}_i = \sum_m w_m \hat{R}_i^{(m)}, \quad w_m \propto \mathrm{BIC}^{(m)}$$

- **稀疏 PCA**：用 L_1 惩罚识别主导因子

Fama-French 六因子模型

FF6 (Fama & French, 2018; 更新 2023–2025)：

$$E[R_i] - r_f = \beta_M \text{MKT} + \beta_S \text{SMB} + \beta_V \text{HML} + \beta_R \text{RMW} + \beta_C \text{CMA} + \beta_U \text{UMD}$$

扩展：

- **流动性因子** (Liu, 2023)：在 FF5 中加入 LIQ
- **人力资本因子** (Khan et al., 2022)：劳动收入增长
- **ESG 因子**：可持续性作为定价因子
- **情绪因子**：基于 FinBERT 的 NLP 情绪

神经 SDF

神经 SDF (Chen et al., 2024)

$$M_t = 1 - \lambda^\top f(\text{特征}_t; \theta)$$

其中 f 为将公司特征映射到因子的神经网络。

优势：

- 数据驱动的因子发现
- 捕捉非线性 SDF
- 在截面检验中优于线性因子模型

挑战：学习到的因子可解释性。

主要参考文献

- Ross, S.A. (1976). The arbitrage theory of capital asset pricing. *JFE*, 13, 341–360.
- Fama, E.F. & French, K.R. (1993). Common risk factors. *JF*, 47, 3–56.
- Fama, E.F. & French, K.R. (2015). A five-factor asset pricing model. *JFE*, 116, 1–22.
- Carhart, M.M. (1997). On persistence in mutual fund performance. *JF*, 52, 57–82.
- Hou, K., Xue, C. & Zhang, L. (2015). Digesting anomalies. *RFS*, 28, 650–705.
- Hansen, L.P. (1982). Large sample properties of GMM. *Econometrica*, 50, 1029–1054.